Panduan Deployment

Sistem berjalan di VPS dan dapat diakses publik melalui Cloudflare Tunnel.

URL Akses

```
https://<url-tunnel-anda>.trycloudflare.com
```

Catatan: URL quick tunnel **berubah setiap kali service di-restart**.
Lihat bagian "Mendapatkan URL Terbaru" di bawah.

Arsitektur Deployment

```
Internet
   │
   ▼
Cloudflare Edge (HTTPS)
   │
   ▼
cloudflared tunnel (di VPS, outbound only)
   │
   ▼
127.0.0.1:8000  ← gunicorn (2 worker)
   │
   ▼
Flask app (NumPy inference, tanpa PyTorch)
```

Mengapa tunnel, bukan buka port: VPS ini bertipe NAT — port masuk ditutup. Cloudflare Tunnel bekerja dengan koneksi keluar dari server, sehingga tidak memerlukan port terbuka maupun IP publik statis.

Spesifikasi Server

Komponen	Nilai
OS	Ubuntu 22.04
CPU	1 vCPU
RAM	2 GB
Disk	78 GB (terpakai 9,4 GB)
Python	3.10

Keputusan penting: PyTorch **tidak** diinstal di server. Bobot model diekspor ke NumPy (`model_weights.npz`) dan forward pass dihitung manual dengan operasi matriks.

Alasannya:
- PyTorch memakan ~1 GB RAM/disk — terlalu berat untuk VPS 2 GB
- Model hanya butuh `Linear + ReLU + Sigmoid`, mudah direplikasi
- Hasil **identik**: selisih maksimum $1{,}2\times10^{-7}$ (batas presisi float32), diverifikasi pada 200 input acak di `src/verify_parity.py`

Konsumsi RAM saat berjalan: ~394 MB dari 1963 MB.

Service Systemd

Dua service berjalan otomatis saat boot:

Service	Fungsi
`credit-app.service`	gunicorn menjalankan Flask di 127.0.0.1:8000
`credit-tunnel.service`	cloudflared menghubungkan ke internet

Keduanya `enabled` (auto-start) dan `Restart=always` (auto-restart jika crash).

Perintah Operasional

```
# Status
systemctl status credit-app credit-tunnel

# Restart
sudo systemctl restart credit-app

# Lihat log
sudo journalctl -u credit-app -n 50
sudo journalctl -u credit-tunnel -n 50

# Hentikan sementara
sudo systemctl stop credit-app credit-tunnel
```

Mendapatkan URL Terbaru

Quick tunnel menghasilkan domain acak setiap restart:

```
sudo journalctl -u credit-tunnel --no-pager -n 50 | grep -oE 'https://[a-z0-9-]+\.trycloudflare\.co
```

Update Aplikasi

Dari komputer lokal:

```
$pw = 'PASSWORD'
$hk = "SHA256:UkZEhpeWkvTYkyrN1OYoHCrjsCdp6ct6uVlMFPXmw+k"

pscp -P VPS_PORT -pw $pw -hostkey $hk "src\server.py" ubuntu@VPS_HOST:/home/ubuntu/credit-app/src/
pscp -P VPS_PORT -pw $pw -hostkey $hk "src\templates\index.html" ubuntu@VPS_HOST:/home/ubuntu/credi

plink -ssh -P VPS_PORT -l ubuntu -pw $pw -hostkey $hk VPS_HOST "sudo systemctl restart credit-app"
```

Jika model dilatih ulang, ekspor dulu bobotnya:

```
# di lokal
cd src
python train.py
python export_weights.py

# lalu upload artifacts/metrics.json dan artifacts/model_weights.npz
```

Struktur di Server

```
/home/ubuntu/
├── venv/                        virtualenv (flask, numpy, gunicorn)
├── credit-app/
│   ├── src/
│   │   ├── server.py            aplikasi Flask
│   │   └── templates/
│   │       └── index.html
│   └── artifacts/
│       ├── metrics.json         parameter standardisasi + hasil evaluasi
│       └── model_weights.npz    bobot model (19 KB)
├── run-tunnel.sh
├── credit-tunnel.service
└── credit-app.service
```

Keamanan

Yang perlu segera dilakukan:

1. **Ganti password VPS.** Password saat ini dikirim melalui chat sehingga harus dianggap sudah bocor.
   `bash passwd`
2. **Pindah ke SSH key dan matikan login password.** Ini menghilangkan risiko brute force sepenuhnya.
   ```bash
   # di lokal: buat key
   ssh-keygen -t ed25519

# kirim public key ke server
type $env:USERPROFILE.ssh\id_ed25519.pub | plink -ssh -P VPS_PORT -l ubuntu -pw "PASSWORD" VPS_HOST "mkdir -p ~/.ssh && cat >> ~/.ssh/authorized_keys"

# di server: matikan login password
sudo sed -i 's/^#*PasswordAuthentication.*/PasswordAuthentication no/' /etc/ssh/sshd_config
sudo systemctl restart ssh
```

3. **Batasi akses SSH** melalui Cloudflare Access atau firewall jika memungkinkan.

Batasan Deployment

1. **URL berubah setiap restart.** Untuk URL permanen diperlukan domain sendiri yang dikelola di dashboard Cloudflare (named tunnel).
2. **Tanpa HTTPS kustom.** Sertifikat mengikuti domain trycloudflare.com.
3. **Tanpa rate limiting.** Endpoint publik dapat dipanggil tanpa batas.
4. **Tanpa autentikasi.** Siapa pun yang memiliki URL dapat mengakses.
5. **Quick tunnel tidak untuk produksi.** Cloudflare menyatakan layanan ini untuk pengujian; untuk produksi gunakan named tunnel.

Mengapa Tidak Training di VPS

VPS memiliki 1 vCPU dan 2 GB RAM. Melatih model pada 30.000 baris data memerlukan waktu jauh lebih lama dan berisiko kehabisan memori.

Alur yang dipakai:

```
Lokal (Windows)          →  VPS (Ubuntu)
train.py (30 epoch)          server.py (inferensi saja)
export_weights.py    ──→     model_weights.npz
```

Training sekali di lokal, hasilnya di-deploy. Ini juga praktik yang lazim: proses pelatihan dan penyajian dipisahkan.